

Análise Comparativa dos Algoritmos Genéticos Many-Objective em problemas de otimização discreta

Gabriel Augusto Marson
gabrielmarson@live.com

4 de outubro de 2016

Resumo

Essa investigação tem como objetivo mostrar o desempenho de alguns algoritmos genéticos multiobjetivos em problemas discretos clássicos da computação assim como em quais circunstâncias são mais adequados.

1 Introdução

Algoritmos genéticos (AGs) apresentam uma abordagem de busca baseada na teoria da evolução de Darwin que adotam uma sequência de passos para atingir um determinado objetivo.

Apesar de ter sido constatado o sucesso dos AGs para certos tipos de problemas, alguns outros permanecem como desafio. Os de otimização discreta com múltiplos objetivos são mais desafiadores pois requerem que a classificação dos indivíduos seja realizada de acordo com vários critérios.

Consideremos, por exemplo, o problema do Roteamento Multicast (PRM). Como foi dito em Bueno [1] ele pode ser modelado como um grafo direcionado onde os vértices são os hosts e as arestas representam os enlaces de comunicação. Dessa forma, dado o grafo G que representa a rede e um fluxo ϕ , deve-se calcular árvores enraizadas T de G para carregar ϕ em G , partindo-se de um vértice que representa o início de uma conexão ou envio de pacote e passando por um subconjunto de vértices de G .

Existe uma série de atributos que podem influenciar o desempenho de uma rede tais como custo, delay, capacidade e tráfego atual. Um AG simples apenas consegue administrar um critério por vez. Os AGs Multi-Objective constituem uma abordagem mais adequada para resolver problemas desse tipo categorizando possíveis melhores respostas em virtude dos critérios avaliados.

Mais recentemente, uma versão mais complexa conhecida por Algoritmos Genéticos Multiobjetivos (AGMOs) foi proposta, na qual o processo de avaliação dos indivíduos leve em consideração diferentes objetivos ou critérios.

A proposta de um AG multi-objectivo como o Non-dominated Sorting Genetic Algorithm II (NSGAI) [2], por exemplo, consiste em classificar vários indivíduos por meio de várias funções objetivo. Dessa forma, utilizou-se o conceito de fronteira de Pareto [3], uma região do espaço de busca na qual estarão os melhores indivíduos de acordo com várias funções objetivo. O critério para a classificação de qual indivíduo permanece em qual fronteira é a dominância.

Diz-se que $x \preceq y$ (x domina y) se:

1. x não é pior do que y para todas as funções objetivos
2. x é melhor do que y em pelo menos uma função objetivo.

Esse tipo de classificação pode ser melhor compreendido se analisarmos um problema simples como a compra de um carro. Vários critérios podem ser utilizados para comprá-lo como preço e desempenho. Assim na fronteira de Pareto, estariam os indivíduos com uma combinação de melhor preço e melhor desempenho. Portanto, não existe uma única resposta para esse tipo de problema.

No NSGAI [2], além do agrupamento por fronteiras, ou rank, utiliza-se também a métrica *crowding distance*, como critério de desempate na escolha do indivíduo caso estejam na mesma fronteira de dominância e, também, para impedir que a variabilidade genética da população seja comprometida.

2 Algoritmos Genéticos

Publicada em 1859, a obra **Na Origem das Espécies – Sob o Conhecimento da Seleção Natural**, de Charles Darwin, foi alvo de críticas pois explicitava que os seres de um ambiente mudam de uma determinada geração para outra e são selecionados de acordo com essas mudanças. A partir disso, Darwin escreveu que todos os seres vivos possuem um ancestral comum, contrastando com a visão criacionista da época.

Essa teoria foi imprescindível para a criação dos algoritmos genéticos por John Henry Holland. Físico formado pelo MIT (Massachusetts Institute of Technology), Holland elaborou um algoritmo não determinístico com foco em resolução de problemas de custo muito alto.

O AG consiste em dar uma interpretação para um conjunto de dados e evoluí-los para uma solução. Nesse caso, todos os dados seriam uma população e cada indivíduo representa um dado, além de ser uma solução em potencial para o problema. O algoritmo avalia cada membro usando uma métrica de aptidão. Isso consiste em dar uma nota para cada indivíduo que simboliza as chances dele transmitir suas características para a próxima geração.

Alguns métodos são utilizados para selecionar os dados. Dessa forma serão escolhidos N pares de pais para realizarem o cruzamento, onde N é o tamanho da população inicial. O processo de troca de material genético chamado crossover retorna um ou mais filhos sendo que existe uma pequena chance (cerca de 1%) de ocorrer uma mutação no material genético dos filhos, em virtude de aumentar a variabilidade na população.

Após o cruzamento, os filhos resultantes são reinseridos na população. Com o intuito de manter o custo computacional não crescente e de eliminar indivíduos fracos, utilizam-se métodos de reinserção para diminuir a população.

Esse processo se repete por um número determinado gerações ou pode ser parado quando todos os indivíduos possuem o mesmo material genético (é improvável que a mutação nas próximas gerações produza um indivíduo mais apto). Percebe-se a semelhança com a teoria de Darwin em que os indivíduos mais adaptados passarão suas características aos seus descendentes.

3 Objetivos

3.1 Objetivos Gerais

Em virtude de bons resultados gerados por esses algoritmos em problemas discretos, tal qual o PRM, serão analisados métodos de AG multi e many objective como NSGAII[2] e SPEA2[4] aplicados a problemas clássicos da computação como o problema da Mochila e do Caixeiro Viajante.

Além desses, pretende-se investigar uma nova família de AGs conhecida como AG *Many-objectives*, por serem apropriados a problemas com vários objetivos. Dentre esses AGMOs, podemos citar o SPEA3 e o AEMMT.

3.2 Objetivos Específicos

- Implementar os algoritmos SPEA2[4] e NSGAII[2]
- Realizar uma análise comparativa com as abordagens já existentes para resolução de problemas discretos com multi objetivos
- Estudo de desempenho de algoritmos *many-objective* como SPEA3 e AEMMT

3.3 Justificativas

Existem muitos problemas de otimização discreta multiobjetivo ainda não resolvidos de forma eficiente. O estudo desses problemas, assim como dos algoritmos que os resolvem, constituem prática importante para embasar novas descobertas com o intuito de otimizar as soluções já existentes ou de criar novas.

3.4 Metodologia

O método científico é o método no qual o pesquisador parte de uma premissa inicial do problema até a sua resposta, no final da pesquisa. Constitui as técnicas que serão utilizadas e os passos seguidos.

Será realizado uma pesquisa descritiva de caráter explicativo com o intuito de construir uma comparação entre os AGMOs e outras abordagens para resolver problemas de otimização discreta multi-objetivo. Pretende-se, também, explicar em quais circunstâncias é indicado o uso dos AGMOs. Para isso, será feito a implementação de alguns AGMOs como SPEA2[4] e NSGAII[2].

Os critérios de comparação serão, inicialmente, a complexidade dos algoritmos segundo a notação O e o desempenho que eles apresentam em problemas de otimização discreta. A princípio, serão testados problemas de maximização e minimização de funções propostos nos artigos de NSGAI[5] e NSGAII[2] em virtude de verificar o desempenho dessas abordagens em funções mais simples.

Em seguida, os algoritmos serão aplicados em problemas mais complexos, tidos como clássicos, na computação. São os problemas da mochila e do caixeiro viajante. Espera-se que os AGMOs apresentem desempenho superior aos algoritmos convencionais quando aplicados a problemas de, no máximo, três objetivos.

O desempenho dos AGMOs diminuem consideravelmente a medida que uma maior quantidade de funções é requerida pelo problema, portanto, torna-se necessário o estudo dos algoritmos genéticos *many-objective*. Será feita uma análise descritiva do algoritmo bem como uma comparação da capacidade de custo e resolução dos algoritmos atuais.

3.5 Cronograma

As atividades principais para desenvolver o artigo são:

- Estudo dos AGMOs(EAGMOs)
- Implementação dos AGMOs(IAGMOs)
- Análise Comparativa(AC)
- Estudo de Algoritmos Many-Objective(EMany-O)
- Dissertação(D)

Sendo que o planejamento para elas é o seguinte:

Tabela 1: Cronograma de Atividades

	EAGMOs	IAGMOs	AC	EMany-O	D
Agosto(2016)	X				
Setembro(2016)	X	X			
Outubro(2016)	X	X			
Novembro(2016)		X	X		
Dezembro(2016)		X	X		
Janeiro(2017)			X		X
Fevereiro(2017)				X	X
Março(2017)				X	X
Abril(2017)				X	X
Mai(2017)					X
Junho(2017)					X

Referências

- [1] M. L. d. P. Bueno, “Heurísticas e algoritmos evolutivos para formulações mono e multiobjetivo do problema do roteamento multicast,” 2010.
- [2] K. Deb, A. Pratap, S. Agarwal, and T. Meyarivan, “A fast and elitist multiobjective genetic algorithm: Nsga-ii,” *IEEE Transactions on Evolutionary Computation*, vol. 6, pp. 182–197, Apr 2002.
- [3] D. A. Van Veldhuizen and G. B. Lamont, “Evolutionary computation and convergence to a pareto front,” in *Late breaking papers at the genetic programming 1998 conference*, pp. 221–228, Citeseer, 1998.
- [4] E. Zitzler, M. Laumanns, L. Thiele, *et al.*, “Spea2: Improving the strength pareto evolutionary algorithm,” in *Eurogen*, vol. 3242, pp. 95–100, 2001.
- [5] N. Srinivas and K. Deb, “Multiobjective optimization using nondominated sorting in genetic algorithms,” *Evolutionary computation*, vol. 2, no. 3, pp. 221–248, 1994.